Cem anos de perdão

LINGUAGEM DE PROCESSAMENTO NATURAL

LEDA ELLEN
CAMILY VOLTAN

SUMÁRIO

- Pré – Processamento: Cem anos de perdão
- TF-IDF
- N-Gram
- WordCloud
- Normalização L1 e L2
- Lei ZIPF
- Média e o máximo de termos e caracteres por categoria

FREQUÊNCIA DE TERMOS
Tokenização e Limpeza

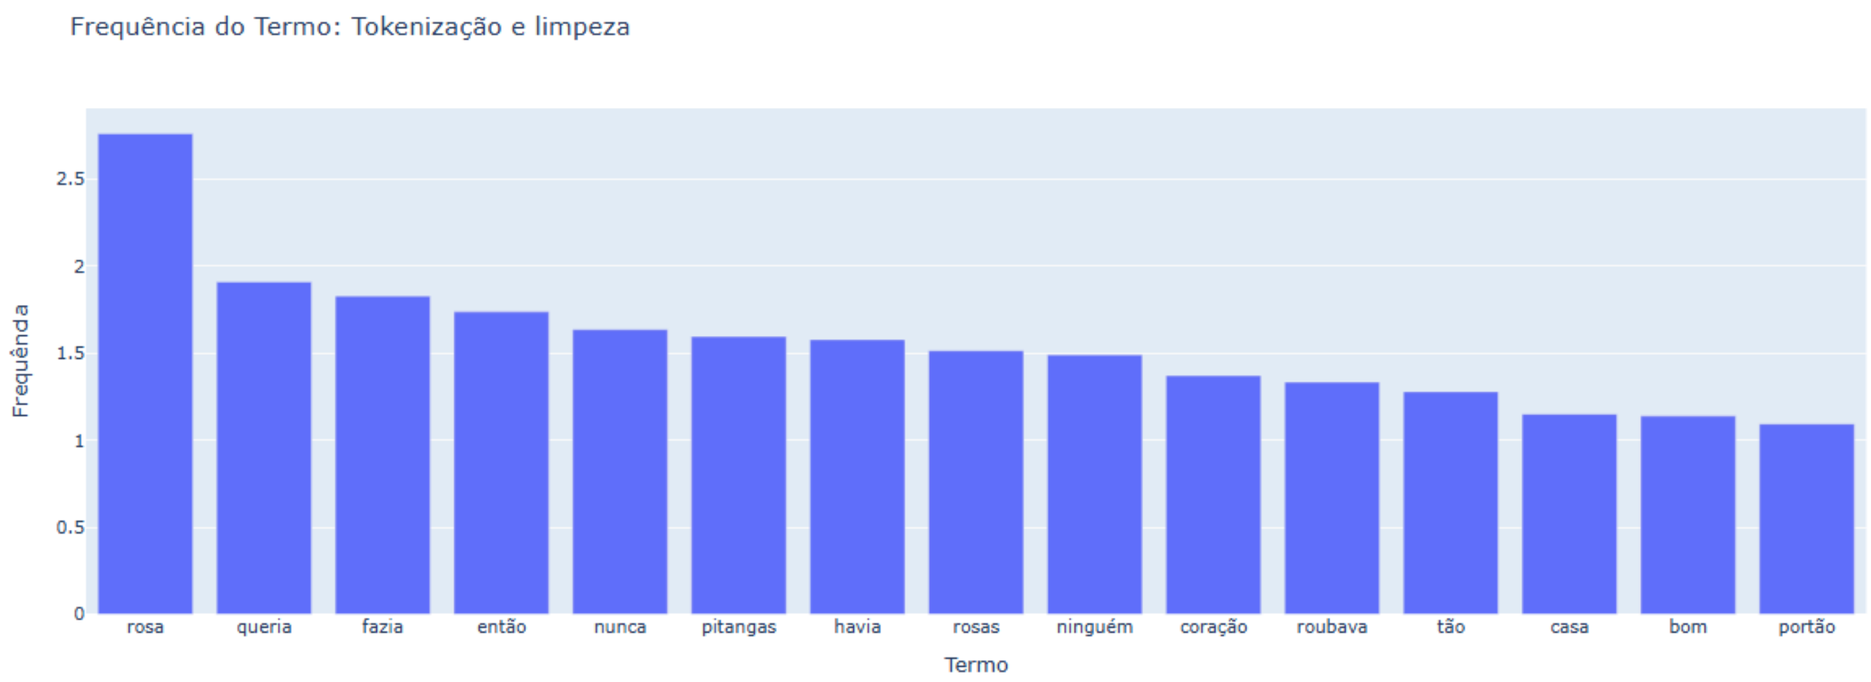

FREQUÊNCIA DE TERMOS
Tokenização e derivações

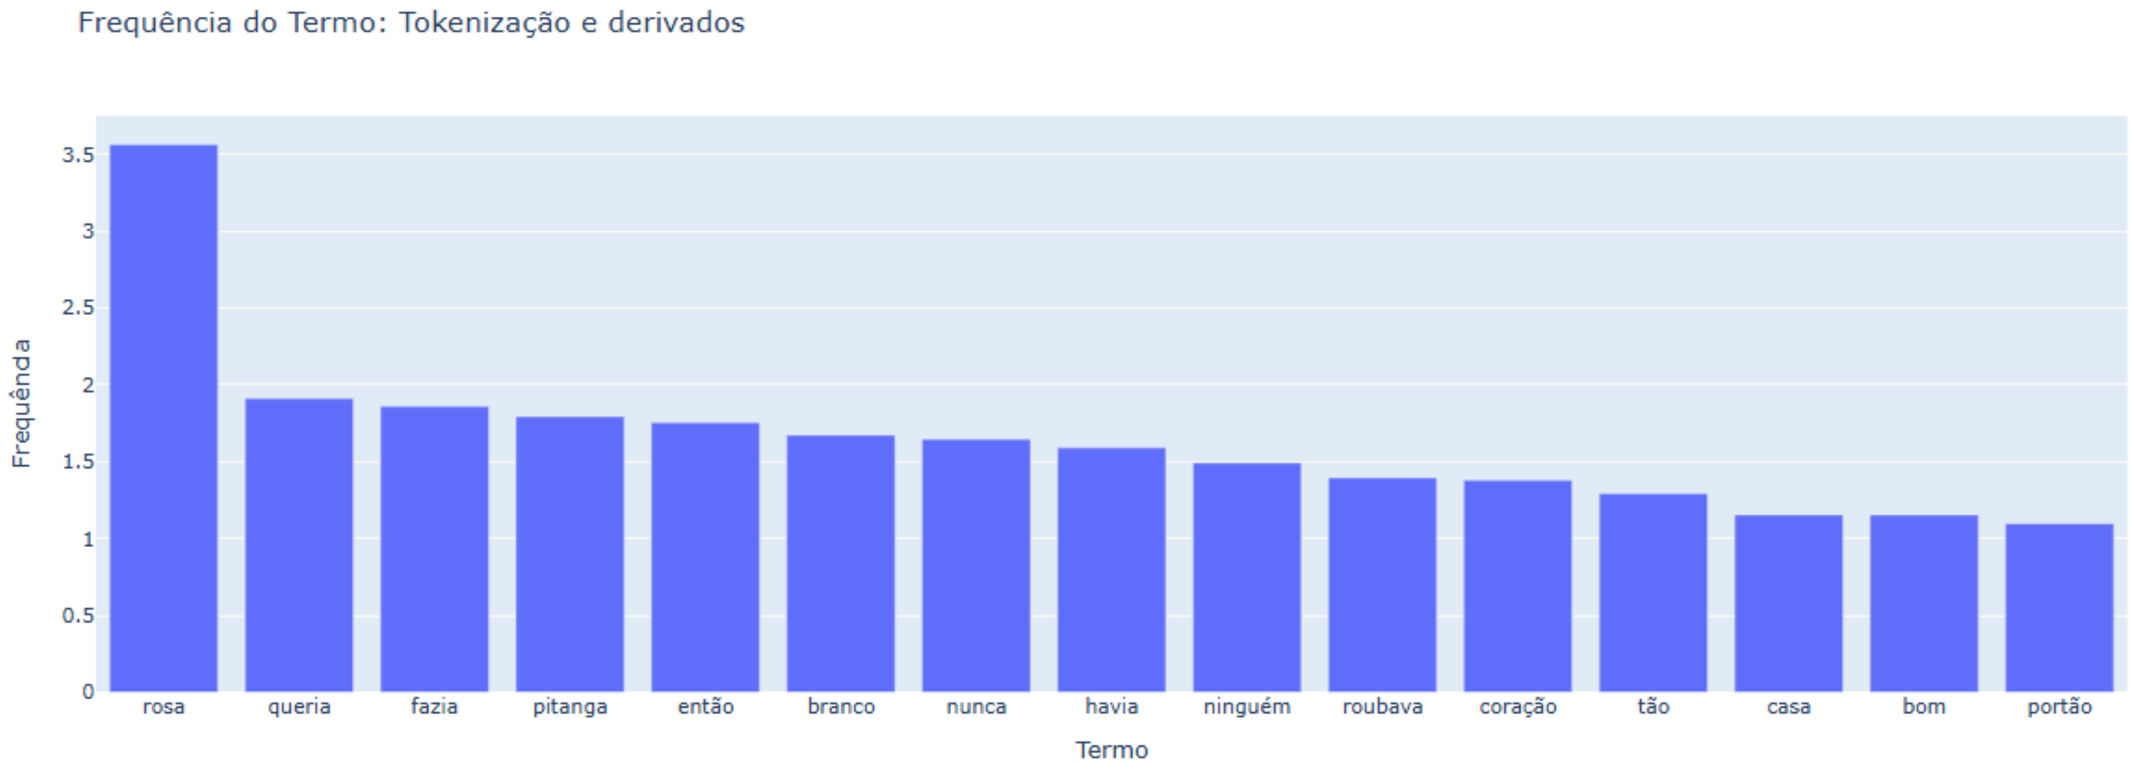

FREQUÊNCIA DE TERMOS
Tokenização e lemmatização

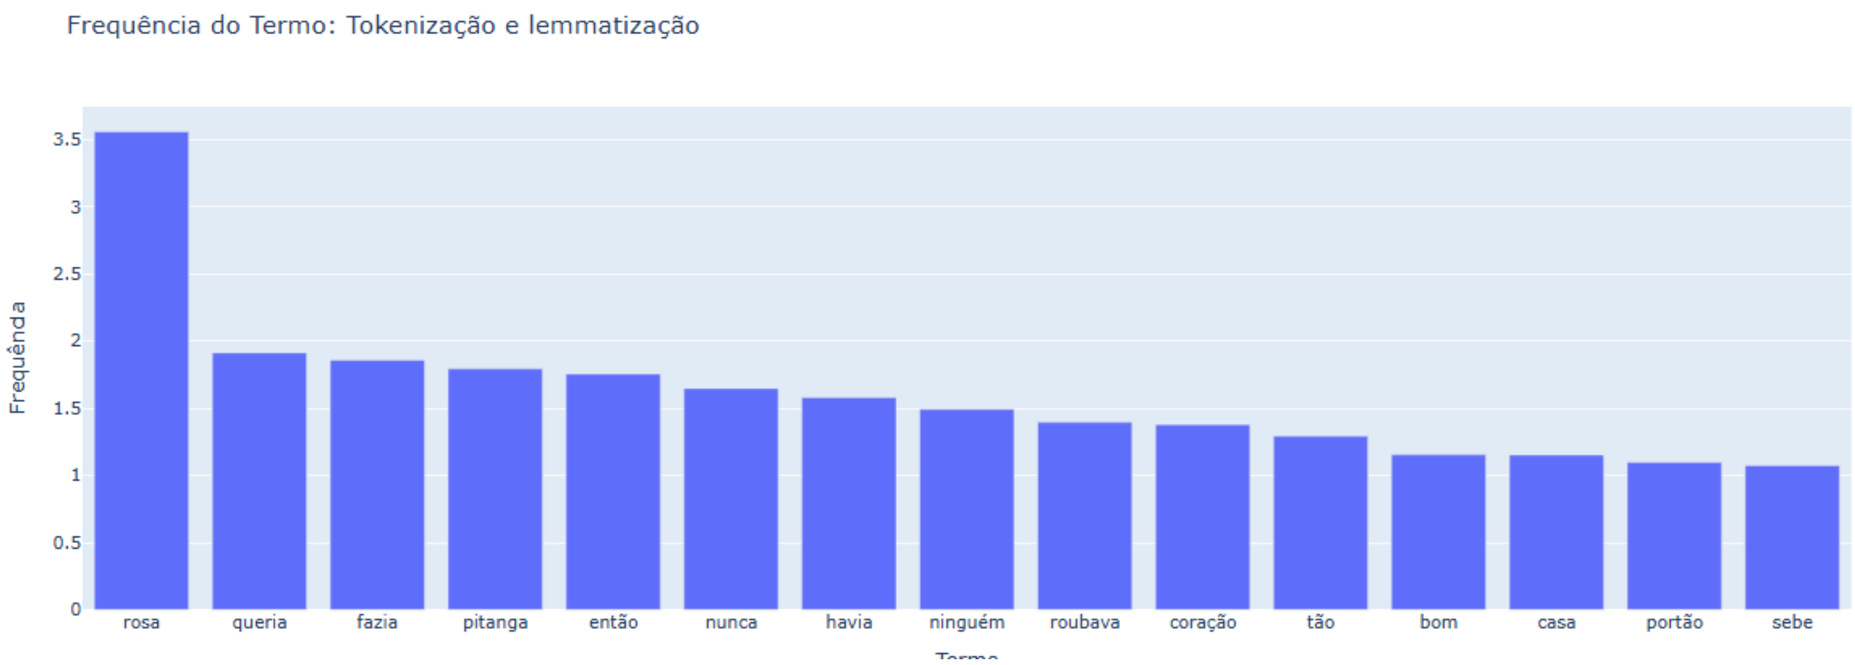

Frequência de Termo - Unigram

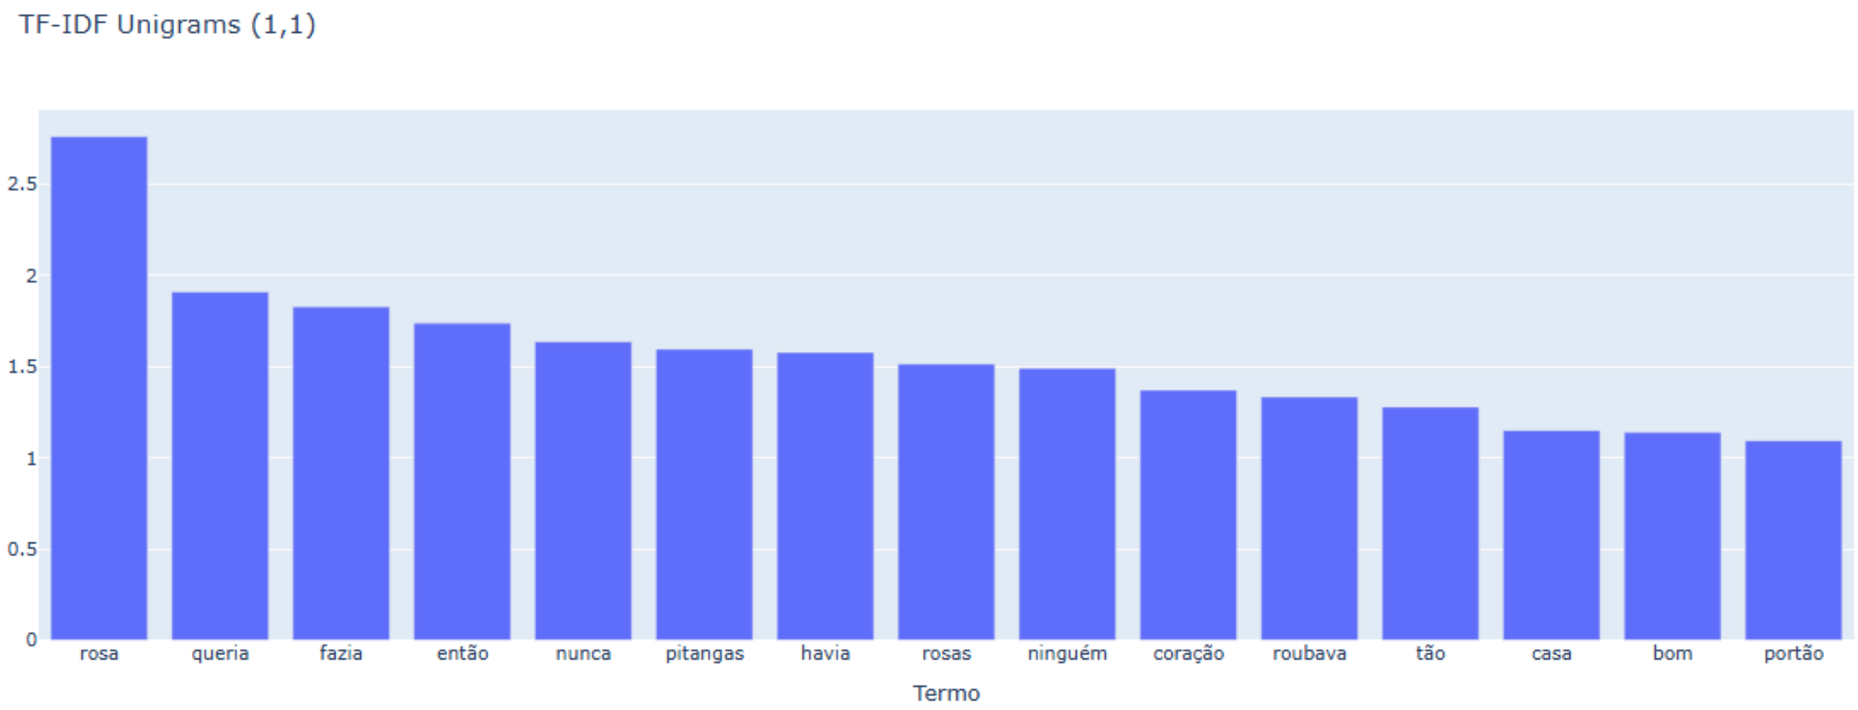

Frequência de Termo - Unigram e Bigram

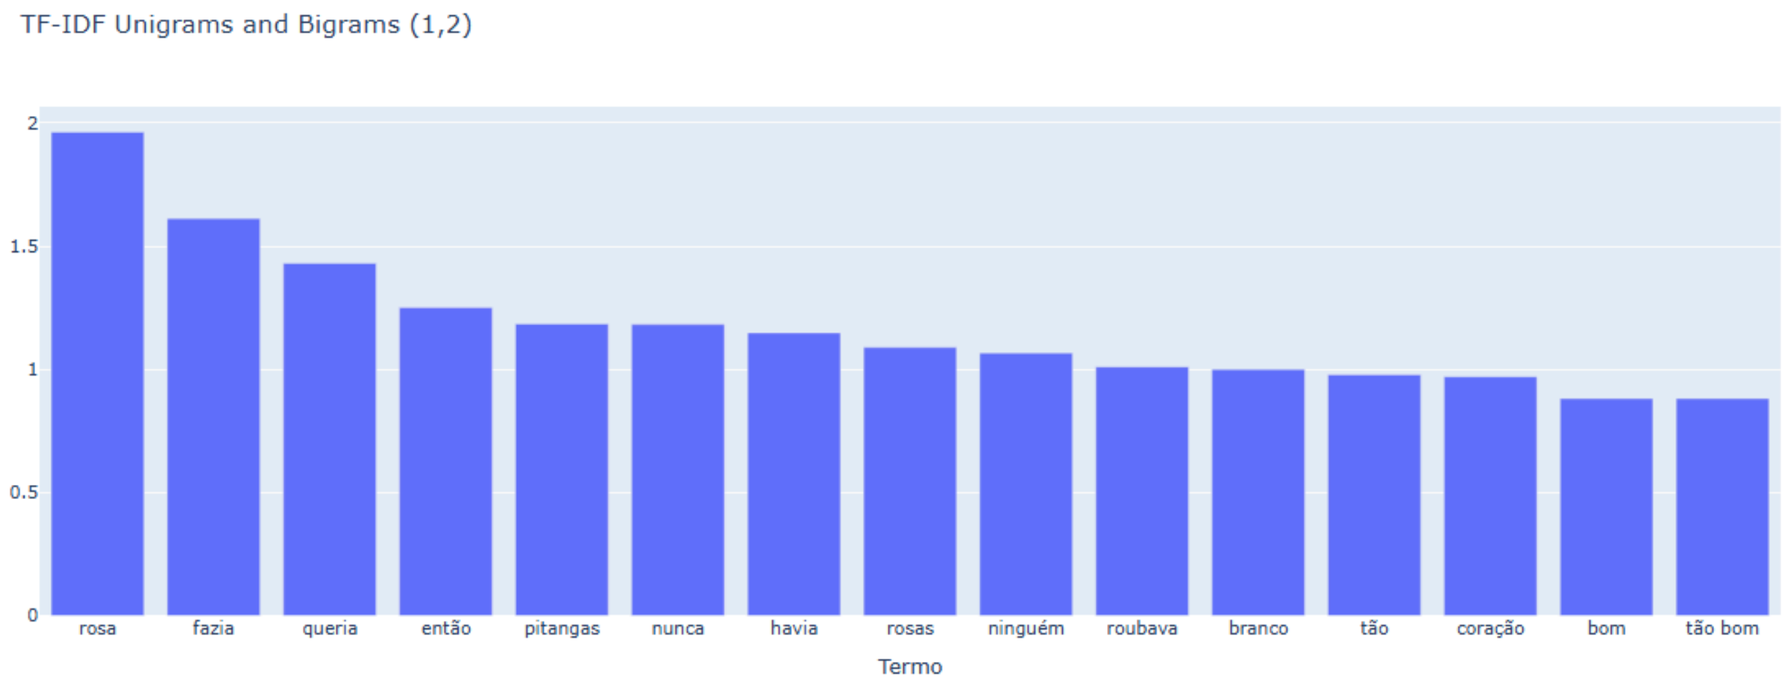

Frequência de Termo - Bigram

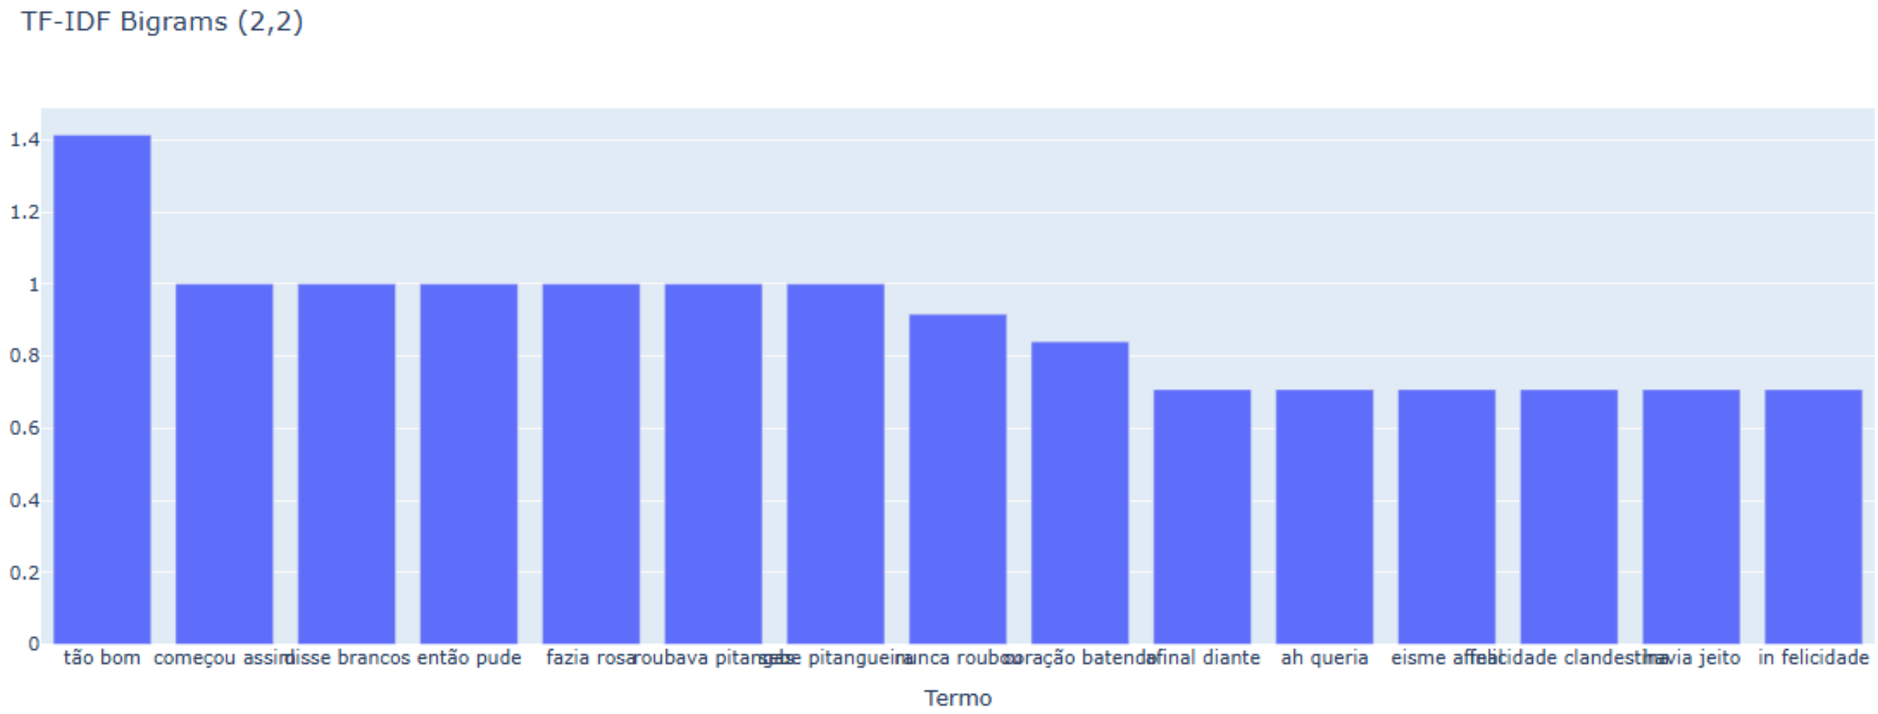

Frequência de Termo – Bigram e Tigram

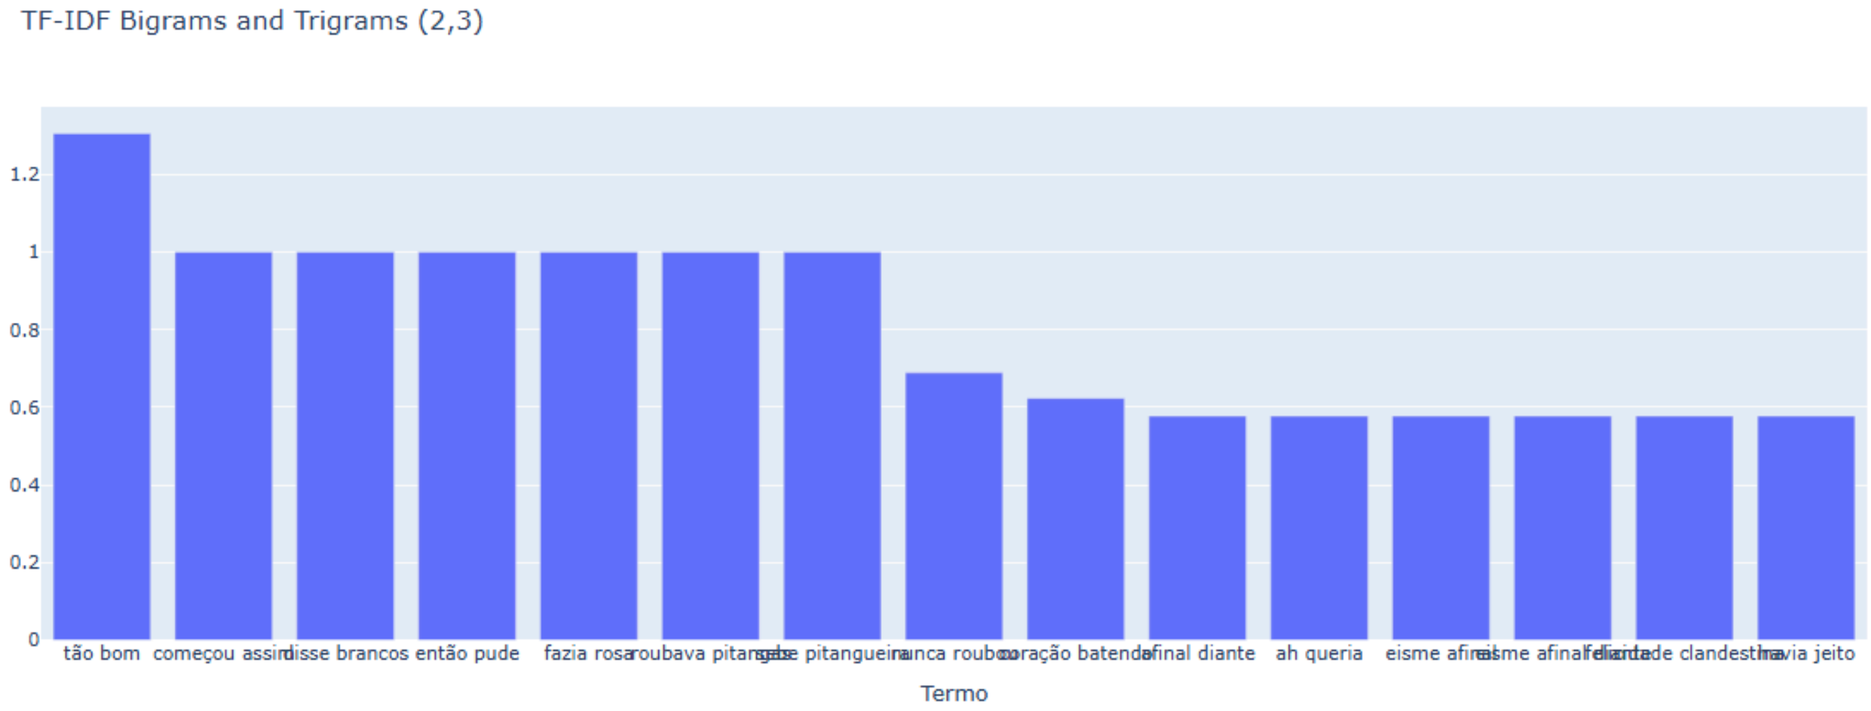
TF-IDF Bigrams and Trigrams (2,3)
1.2
1
0.8
0.6
0.4
0.2
0
tão bom
começou assim
disse brancos
então pude
fazia rosa
roubava pitangueira
pitangueira
nunca roubava
coração batendo
afinal diante
ah queria
eismeafinal
eismeafinal
eismeafinal

WordCloud – Tokenização e limpeza

WordCloud: Tokenização e limpeza

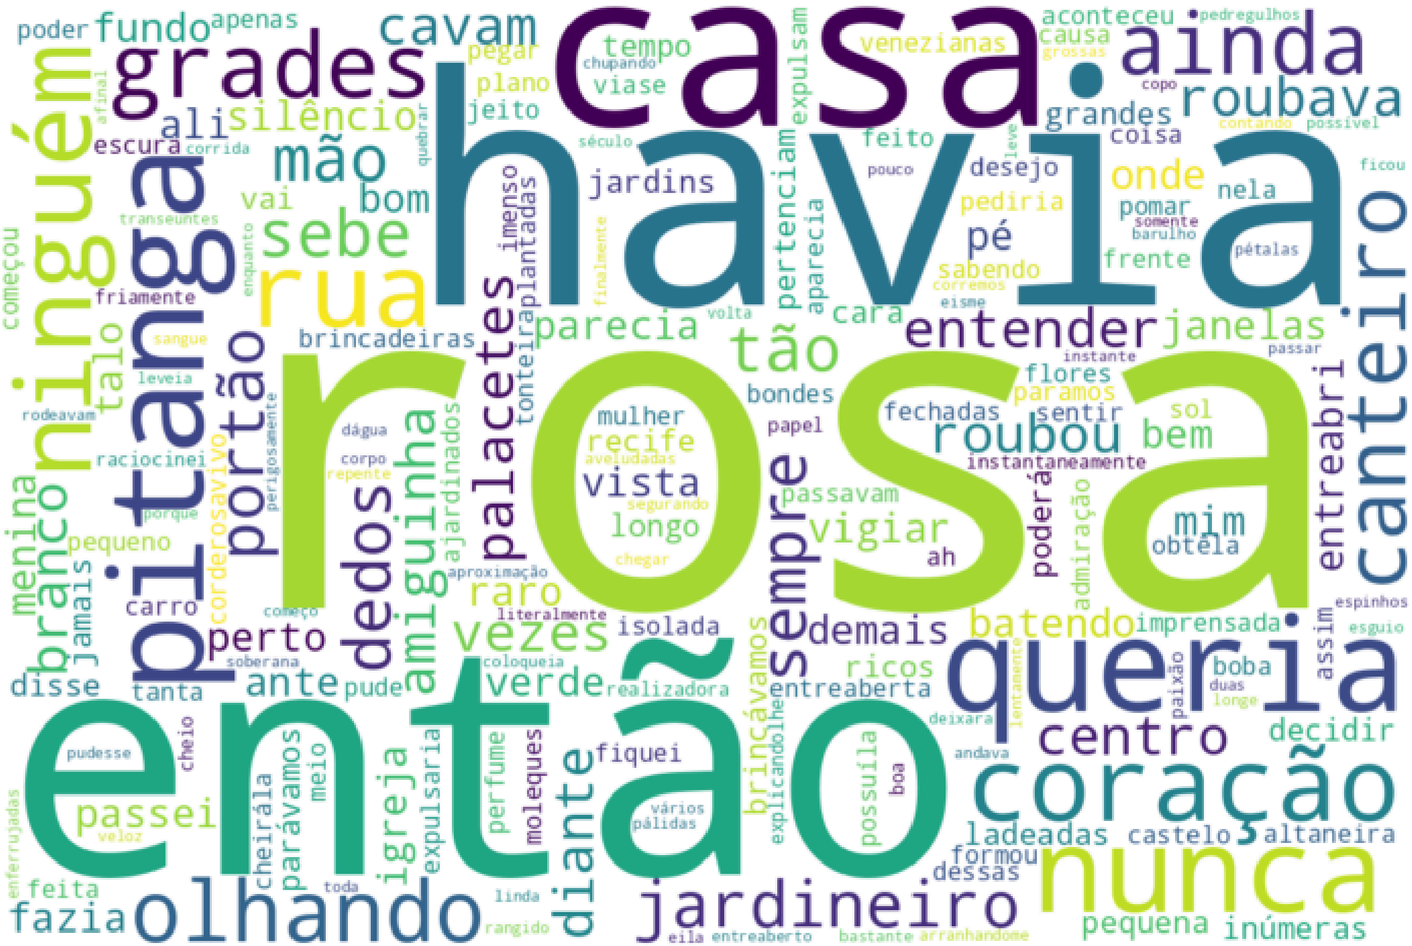

WordCloud - Tokenização e derivações

WordCloud: Tokenização e derivados

WordCloud – Tokenização e lemmatização

WordCloud: Tokenização e lematização

RESULTADO - Sem o Stopwords

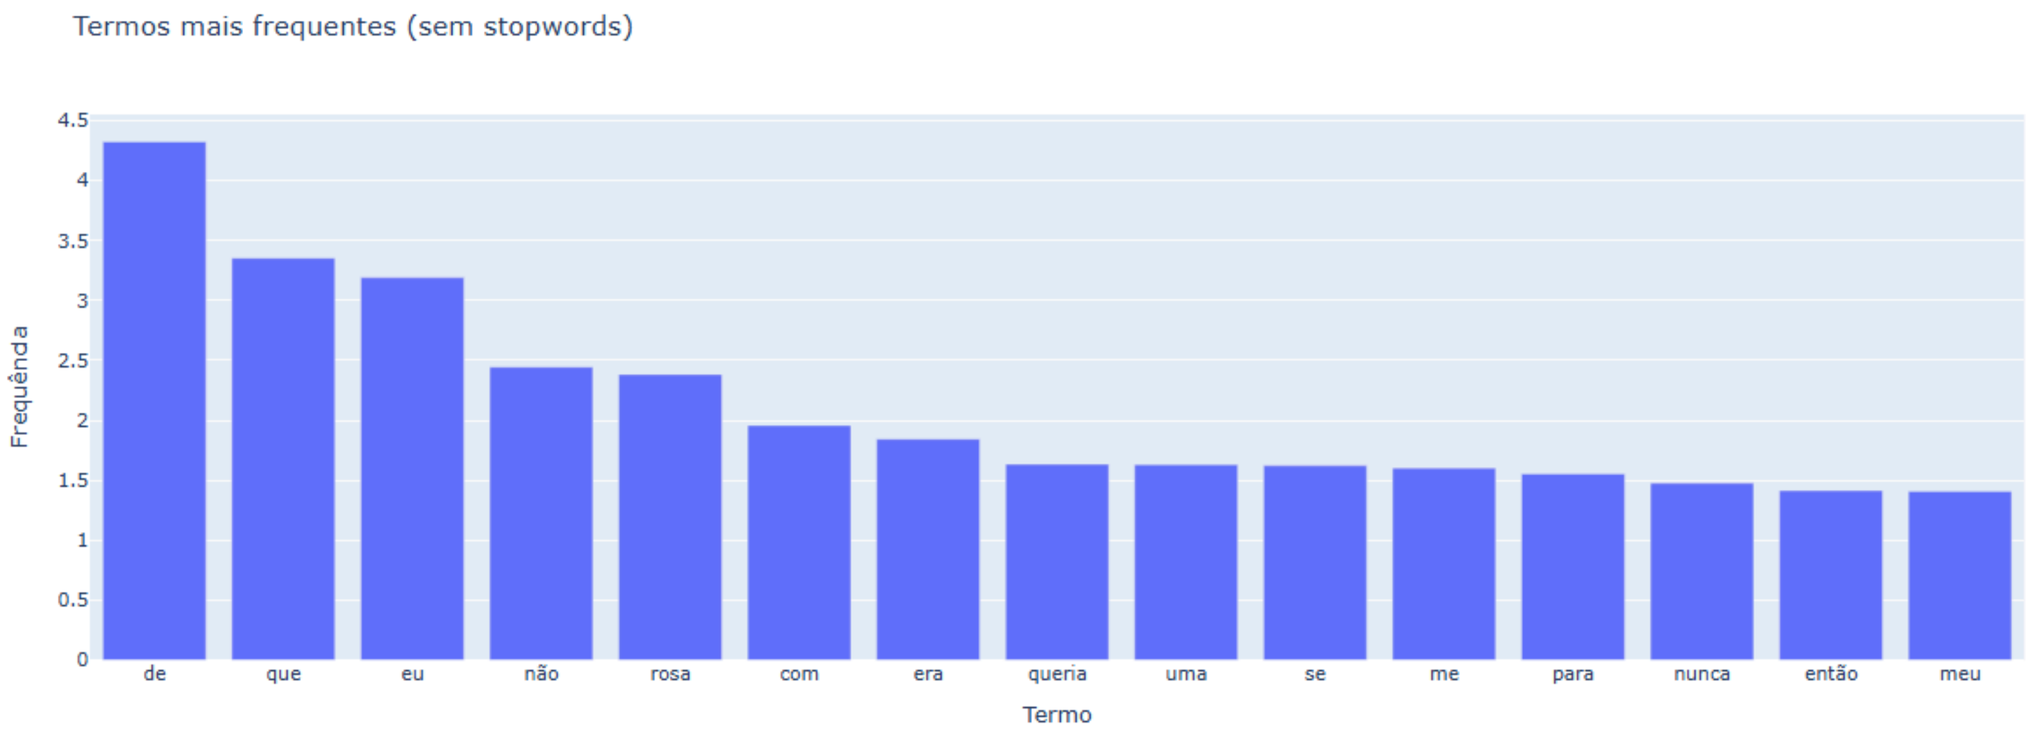

Normalização L1 e L2

```
Mean L1 norm: 1.0
Mean L2 norm: 1.0
Mean L1 norm: 1.0
Mean L2 norm: 1.0
Mean L1 norm: 0.9655172413793104
Mean L2 norm: 0.9655172413793104
Mean L1 norm: 0.9655172413793104
Mean L2 norm: 0.9655172413793104
```

LEI DE ZIPF: Tokenização e Limpeza

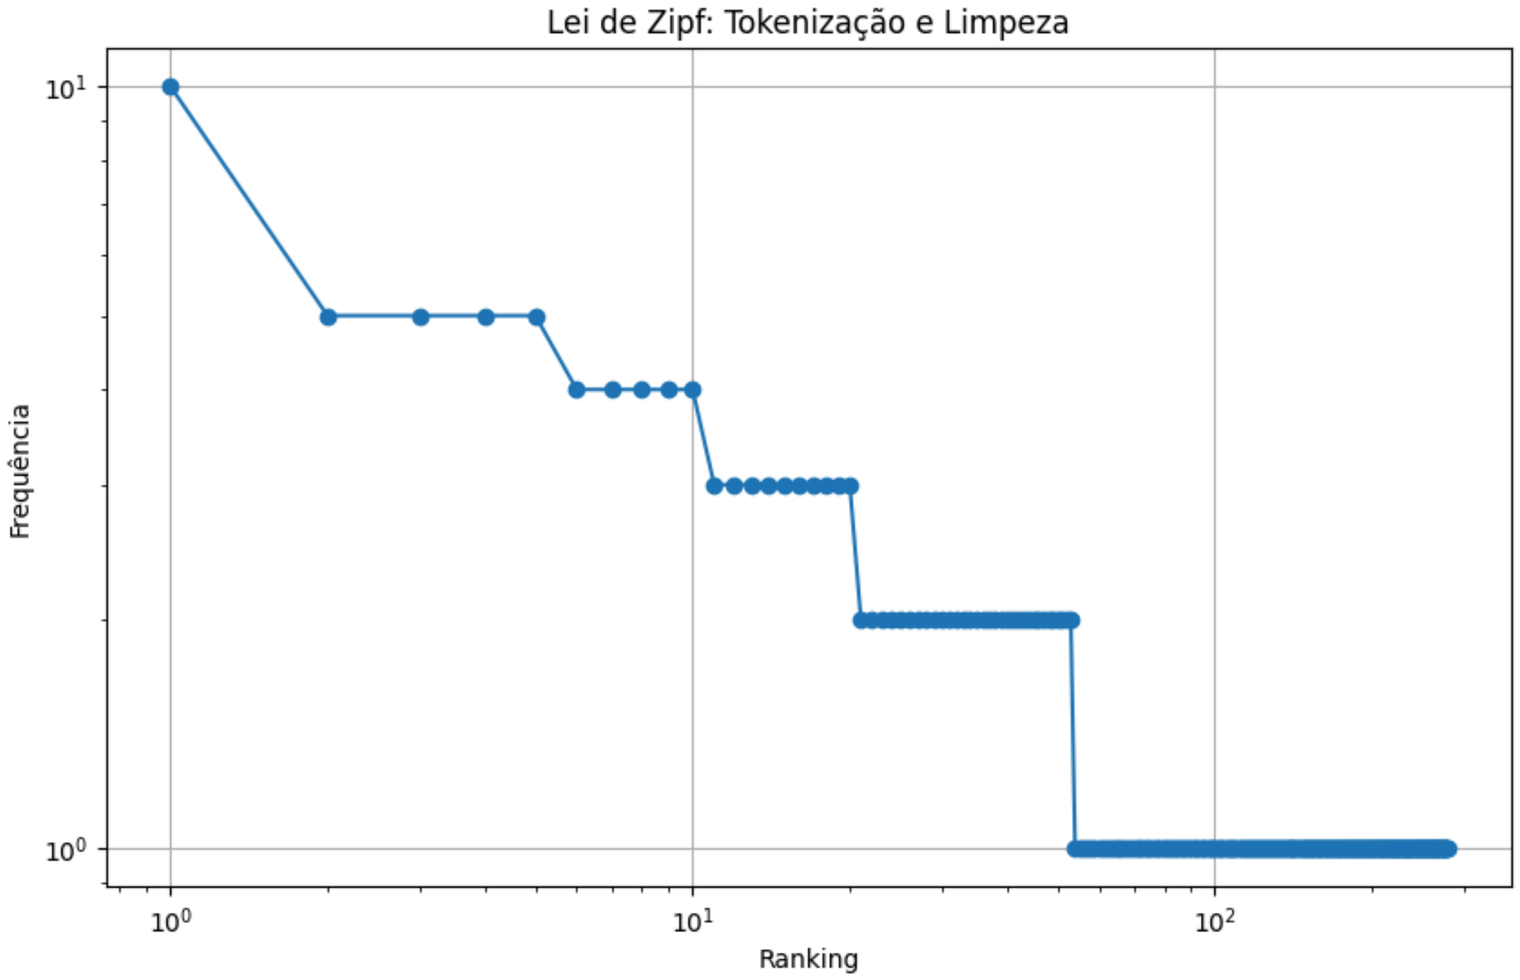

LEI DE ZIPF: Tokenização e derivações

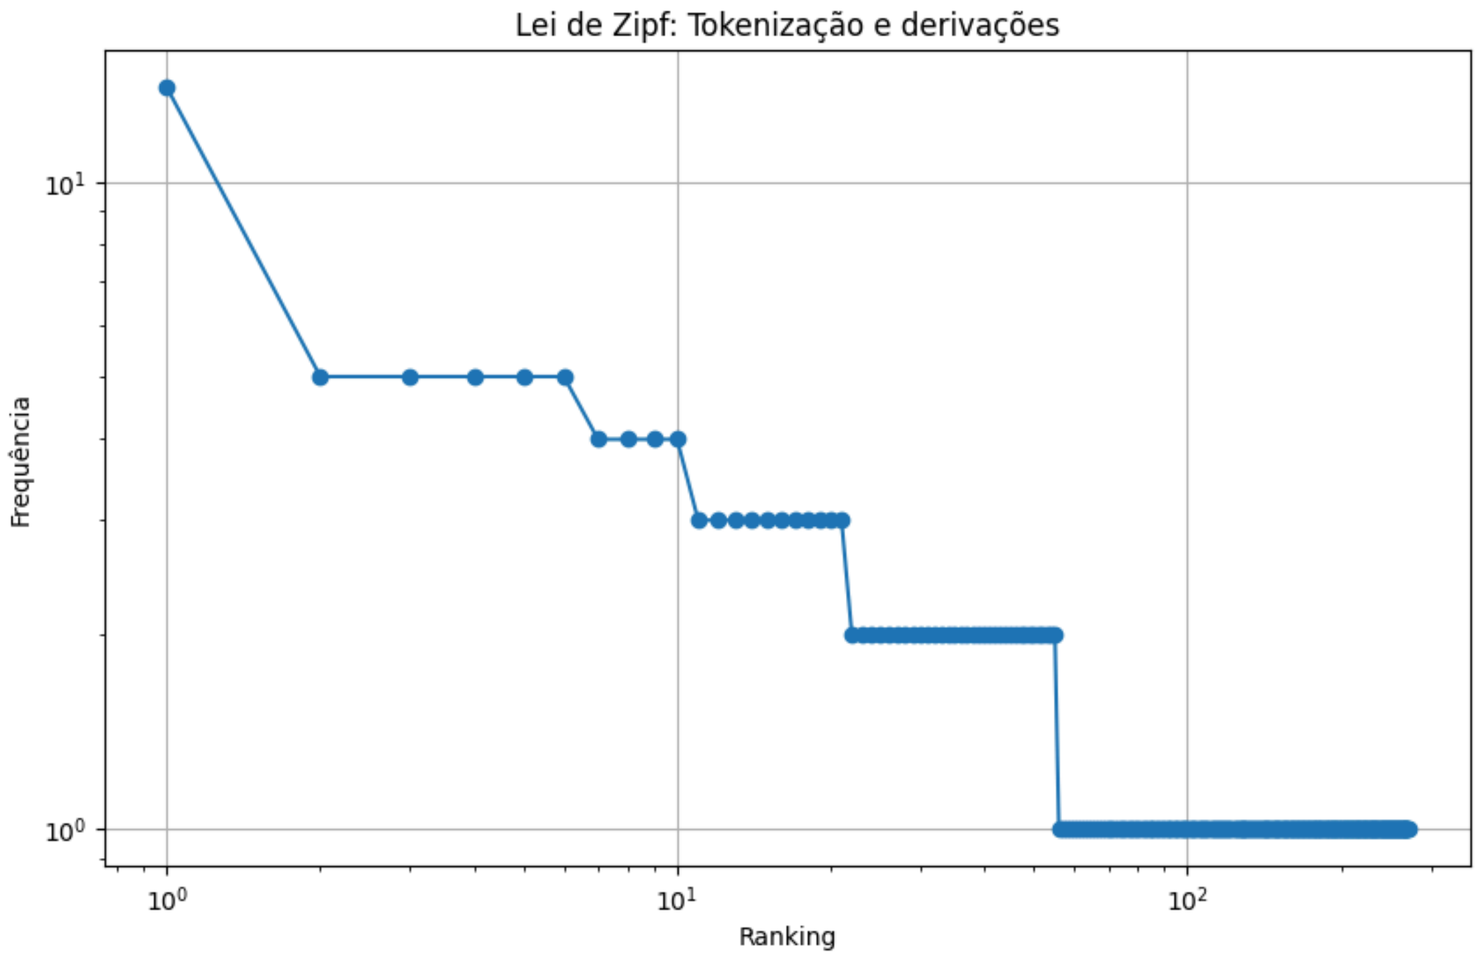

LEI DE ZIPF: Tokenização e lemmatizações

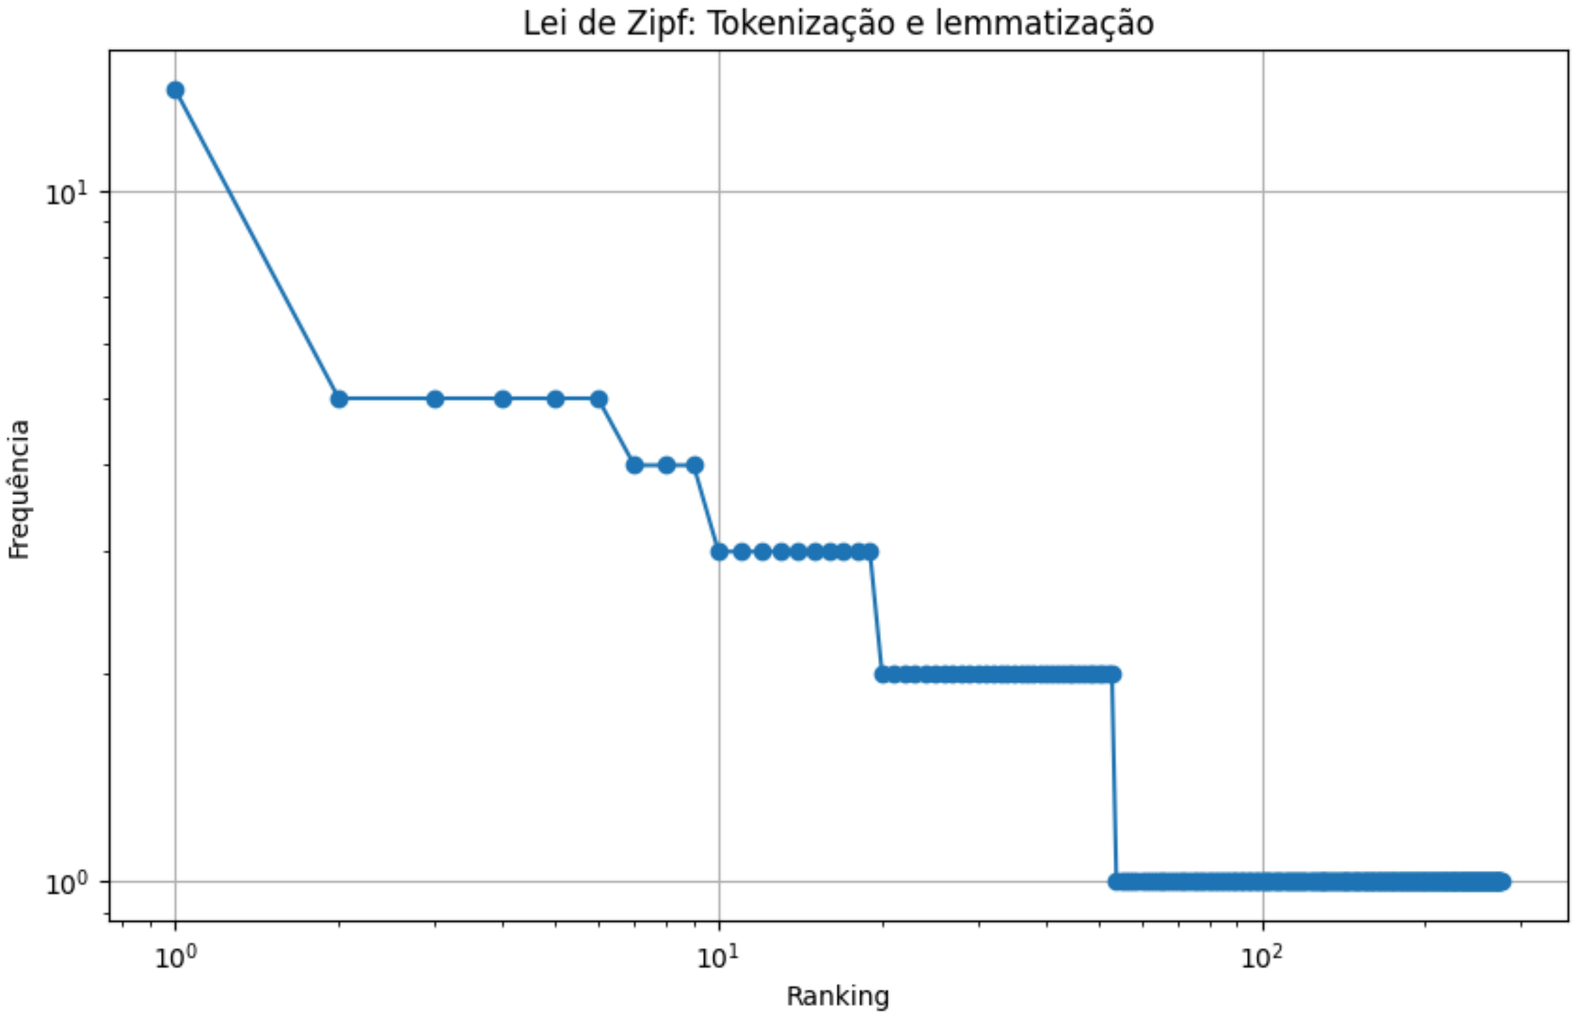
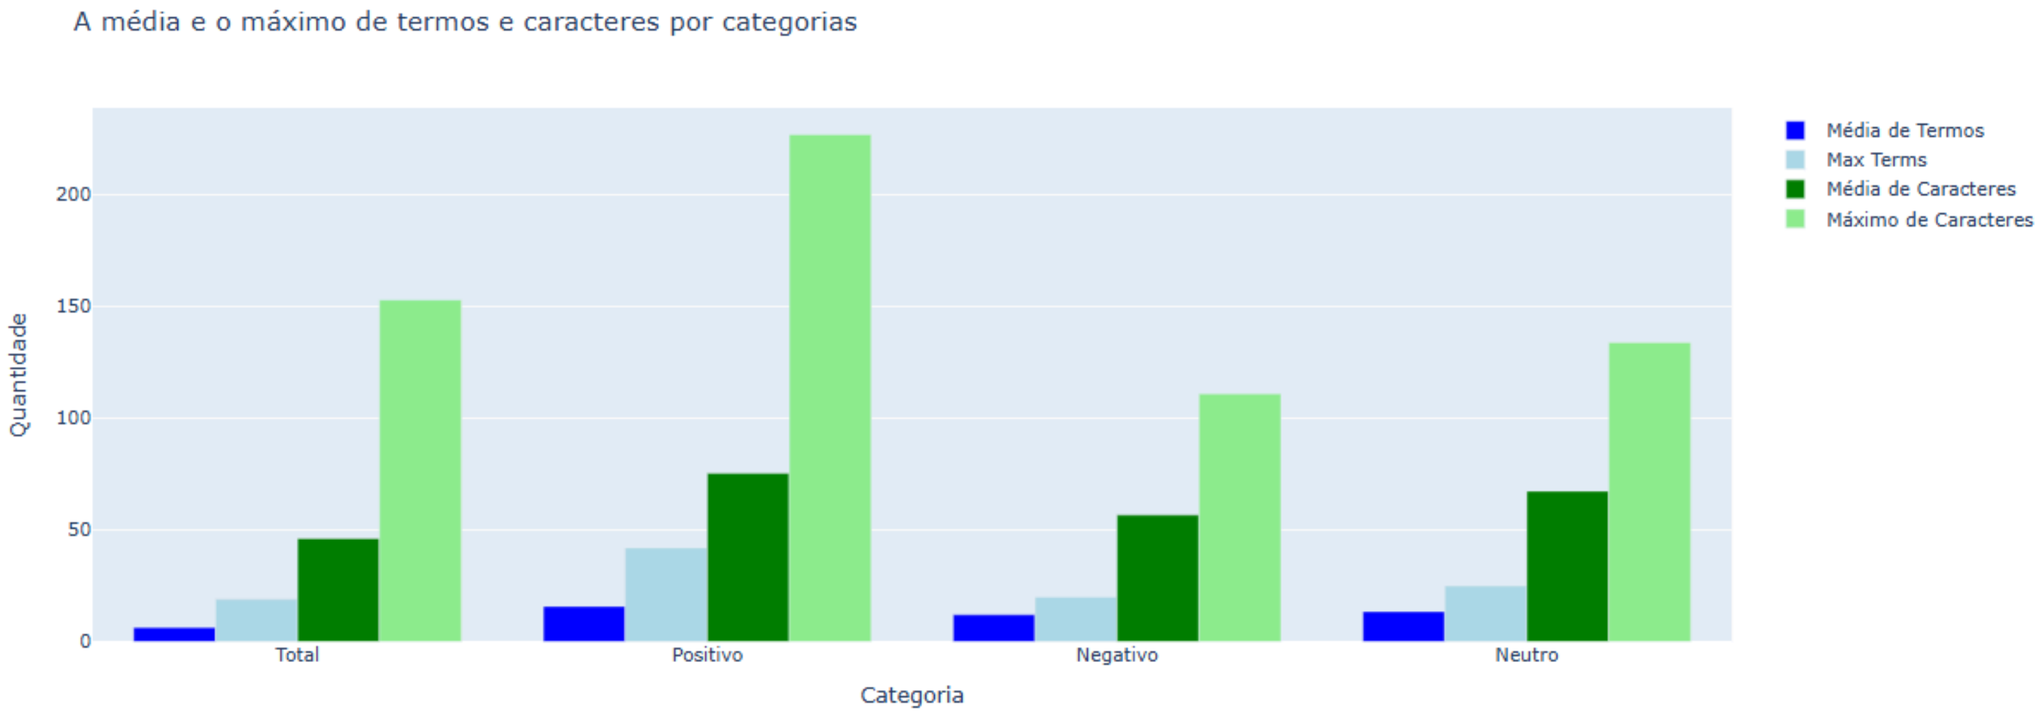
A Média e o Máximo de termos e caracteres por categorias